

Tối ưu tốc độ Hybrid Router

Đánh giá ba phương án: ghim model General/OTHER, giữ cache lâu hơn và ổn định tuyến

Kết luận chính: Thời gian end-to-end trung bình giảm từ 36,53 giây xuống 15,00 giây (-58,9%). Router latency giảm 83,2%, model-switch latency giảm 66,6% và tỷ lệ cache hit tăng từ 16,7% lên 50%.

1. Mục tiêu và phạm vi

Báo cáo đánh giá hiệu quả của các thay đổi nhằm giảm thời gian phản hồi trong chế độ Hybrid Router, đặc biệt khi hội thoại liên tục chuyển giữa OTHER, MATH, HISTORY và ENGLISH. Phạm vi gồm số liệu baseline từ tệp export ban đầu, các thay đổi đã triển khai, kết quả benchmark lại và hướng xử lý hội thoại dài.

2. Thiết lập kiểm thử

Hạng mục	Thiết lập
Nguồn baseline	D:\manual_hybrid_speed_2026-07-24T11-20-42-371Z.json
Số lượt	6 lượt, hoàn thành 6/6
Chuỗi chủ đề	OTHER → MATH → MATH → OTHER → HISTORY → ENGLISH
Giới hạn sinh	256 output tokens/lượt
Tham số	temperature 0,7; top-k 50; top-p 0,95; repetition penalty 1,1
Model	OTHER, MathQwen, HistoryQwen7, English_Qwen

Lưu ý dữ liệu: trường cấu hình tổng quát trong file export ghi maxNewTokens = 512, nhưng từng lượt đo thực tế đều ghi max_new_tokens = 256. Báo cáo sử dụng giá trị thực tế theo từng lượt và benchmark sau cũng giữ mức 256.

3. Thông số trước tối ưu

Chỉ số	Baseline
Router latency trung bình	1.548,8 ms
Model-switch latency trung bình	23.130,5 ms
Generation latency trung bình	11.266,0 ms
TTFT trung bình	2.361,2 ms
End-to-end trung bình	36.530,3 ms
End-to-end trung vị	23.850 ms
End-to-end P95	60.346 ms
Cache hit	1/6 (16,7%)
Switch load / eviction	4 / 4
Input token lớn nhất	1.081 tokens
Lượt chạm output cap	3/6

4. Vấn đề được xác định

Model thrashing: chỉ dùng một GPU slot khiến OTHER bị đẩy ra khi gọi model chuyên môn và phải tải lại khi quay về hội thoại chung.

Router lặp lại: các câu tiếp nối cùng môn vẫn gọi router LLM, tạo thêm khoảng 1–5 giây dù không cần đổi model.

Lịch sử tăng tuyến tính: toàn bộ hội thoại được gửi lại ở mỗi lượt; input token tăng từ 268 lên 1.081, làm tăng chi phí tokenize/prefill và TTFT.

Cache chưa tối ưu: model phổ biến không được ghim riêng, dẫn đến 4 lần eviction trong 6 lượt.

5. Các giải pháp đã áp dụng

#	Giải pháp	Cách triển khai	Tác động kỳ vọng
1	Ghim General/OTHER	OTHER đóng vai trò model tổng quát, preload và ghim ở slot 1. Specialist chỉ luân chuyển tại slot 2.	Loại bỏ việc tải lại OTHER khi quay về giao tiếp chung.
4	Giữ cache lâu hơn	Không unload sau từng câu; lưu trạng thái pinned, loaded_at và last_used_at. Chỉ thay specialist khi cần.	Tăng cache hit và giảm eviction.
5	Route stabilization	Giữ sticky route theo session trong 30 phút. Nếu không có tín hiệu đổi môn rõ ràng thì tái sử dụng subject/model trước đó.	Câu tiếp nối cùng môn không gọi router LLM.
Bổ sung	Giới hạn lịch sử	Chỉ gửi tối đa 2 cặp user/assistant hoàn chỉnh cùng môn, giới hạn 2.400 ký tự.	Chi phí context không còn tăng theo toàn bộ độ dài chat.

6. Kết quả benchmark sau tối ưu

Chỉ số	Trước	Sau	Thay đổi
Router latency TB	1.548,8 ms	260,2 ms	-83,2%
Model-switch TB	23.130,5 ms	7.714,3 ms	-66,6%
Generation TB	11.266,0 ms	6.647,7 ms	-41,0%
End-to-end TB	36.530,3 ms	14.996,3 ms	-58,9%
End-to-end trung vị	23.850 ms	11.314 ms	-52,6%
Cache hit	16,7%	50,0%	Tăng 3 lần
Input token lớn nhất	1.081	410	-62,1%
Model eviction	4	2	-50,0%

6.1. Chi tiết từng lượt sau tối ưu

Lượt	Môn	Route	Router ms	Switch ms	Gen ms	E2E ms	Cache	Input
1	OTHER	rule	40	0	2.707	3.078	Có	268
2	MATH	llm	1.471	14.950	7.165	23.931	Không	272
3	MATH	sticky	7	0	5.995	6.564	Có	410
4	OTHER	rule	1	0	10.903	11.314	Có	400
5	HISTORY	rule	15	15.724	8.617	24.661	Không	272
6	ENGLISH	rule	27	15.612	4.499	20.430	Không	80

Quan sát: Lượt MATH thứ hai sử dụng sticky route nên router chỉ mất 7 ms và không phải đổi model. Lượt ENGLISH chỉ gửi 80 input tokens thay vì 1.081 tokens như baseline.

7. Xử lý hội thoại dài và chuyển model

Cần tách hai loại chi phí: model-switch latency là thời gian tải trọng số model vào GPU; còn lịch sử dài làm tăng tokenize/prefill và thời gian đến token đầu tiên. Việc ghim model xử lý loại chi phí thứ nhất, trong khi cửa sổ lịch sử theo môn xử lý loại chi phí thứ hai.

Mức	Giải pháp	Mô tả
Đã áp dụng	Subject-scoped window	Chỉ lấy tối đa 2 lượt hoàn chỉnh gần nhất thuộc đúng môn đang xử lý, tối đa 2.400 ký tự.
Khuyến nghị tiếp	Rolling summary	Khi lịch sử vượt ngưỡng, tạo bản tóm tắt trạng thái theo từng môn và gửi summary + 1–2 lượt gần nhất.
Khuyến nghị nâng cao	KV/prefix cache	Cache past_key_values theo session và model để tránh prefill lại prefix; cần TTL/LRU và giới hạn VRAM.
Tùy chọn	Relevant-turn retrieval	Truy xuất một số lượt cũ liên quan bằng từ khóa hoặc embedding thay vì gửi toàn bộ hội thoại.

8. Kết luận và giới hạn

Ba phương án 1, 4 và 5 mang lại cải thiện rõ rệt: thời gian end-to-end trung bình giảm 58,9%, model-switch giảm 66,6% và router giảm 83,2%. Kiến trúc hai slot giúp OTHER/General luôn sẵn sàng, còn sticky route loại bỏ các lần phân tuyến không cần thiết.

Kết quả hiện tại dựa trên 6 lượt và chịu ảnh hưởng của tunnel, tải GPU và dao động sinh token. Để có kết luận thống kê ổn định, nên chạy cùng kịch bản từ 3–5 lần, báo cáo trung bình, P50/P95 và độ lệch chuẩn.

Đề xuất ưu tiên tiếp theo: Giữ cấu hình hiện tại, bổ sung rolling summary theo môn trước; chỉ triển khai KV/prefix cache sau khi đo ngân sách VRAM và tỷ lệ session đồng thời.

Phụ lục A. Vị trí triển khai chính

Thành phần	Tệp
Sticky route	backend\src\services\routing\routingOrchestrator.ts
Slot và history window	backend\src\controllers\chatController.ts
Preload/pin từ giao diện	frontend_v2\src\pages\ChatView.tsx
Pinned slot metadata	gpu-service\app.py